PR12-Data Wrangling

조성우

2020 6월10일

1.Data Wrangling with tidyverse

- Data wrangling이란, 분석을 진행하기위해 날것(raw)의 데이터를 분석에 적합한 형태로 정형화시키는 작업입니다.
- R에서는tidyverse라는 패키지 생태계를 구성하고 있어서, 일관성있고 쉬운 작업을 가능하게 합니다.

```
# install.packages("tidyverse")
library(tidyverse)
```

```
## Warning: package 'tidyverse' was built under R version 3.6.3
```

```
## -- Attaching packages ---------------------------------------------------
-------------------------------------------------------------------------
------------------------------------------------------ tidyverse 1.3.0 --

## √ ggplot2 3.3.0.9000     √ purrr   0.3.3
## √ tibble  2.1.3          √ dplyr   0.8.5
## √ tidyr   1.0.2          √ stringr 1.4.0
## √ readr   1.3.1          √ forcats 0.5.0

## Warning: package 'tidyr' was built under R version 3.6.3

## Warning: package 'readr' was built under R version 3.6.3

## Warning: package 'dplyr' was built under R version 3.6.3

## Warning: package 'stringr' was built under R version 3.6.3

## Warning: package 'forcats' was built under R version 3.6.3

## -- Conflicts ------------------------------------------------------------
-------------------------------------------------------------------------
------------------------------------------- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()    masks stats::lag()
```

2.tidyr

*tidyr은Handley wicham이 만든 데이터의 포맷을 변경하기위한 패키지

tidyr의 주요함수

```
#gather() : 데이터를 wide 에서 long 포맷으로 변경
#spread() : 데이터를 long 에서 wide 포맷으로 변경
#seperate() : 단일 열(column)을 복수 열들로 분리
#unite() : 복수 열(column)들을 단일 열로 결합
```

tidyr 실습데이터: cases in EDAWR

*Dataset to support the Expert Data Analysis with R : EDAWR

```
#install.packages("devtools")
#devtools::install_github("rstudio/EDAWR")

library(EDAWR)
```

```
##
## Attaching package: 'EDAWR'
```

```
## The following object is masked from 'package:dplyr':
##
##     storms
```

```
## The following objects are masked from 'package:tidyr':
##
##     population, who
```

```
head(cases)
```

```
##   country  2011  2012  2013
## 1      FR  7000  6900  7000
## 2      DE  5800  6000  6200
## 3      US 15000 14000 13000
```

```
head(pollution)
```

```
##       city  size amount
## 1 New York large     23
## 2 New York small     14
## 3   London large     22
## 4   London small     16
## 5  Beijing large    121
## 6  Beijing small     56
```

```
head(storms)
```

```
##     storm wind pressure       date
## 1 Alberto  110     1007 2000-08-03
```

```
## 2    Alex   45     1009 1998-07-27
## 3 Allison   65     1005 1995-06-03
## 4     Ana   40     1013 1997-06-30
## 5  Arlene   50     1010 1999-06-11
## 6  Arthur   45     1010 1996-06-17
```

2.1.gather() 함수

- wide포맷의 데이터를 원하는 조건에 맞게long포맷으로 변환하는 함수
- gather(데이터,키(key),값(Value),...) *...: 원데이터로 부터 모으기(gather)가 진행될 열들의 범위

```
gather(cases, Year,n,2:4)
```

```
##   country Year     n
## 1      FR 2011  7000
## 2      DE 2011  5800
## 3      US 2011 15000
## 4      FR 2012  6900
## 5      DE 2012  6000
## 6      US 2012 14000
## 7      FR 2013  7000
## 8      DE 2013  6200
## 9      US 2013 13000
```

2.2.spread() 함수

- long포맷의 데이터를 원하는 조건에 맞게long포맷으로 변환하는 함수
- seperate(데이터,키(key),값(value),~) ** 키(key):복수개의 열로spread될 기존long포맷의 열이름 **값(Value):복수개의 열로spread되어 값이 될 기존long포맷의 열이름

```
spread(pollution,size,amount)
```

```
##       city large small
## 1  Beijing   121    56
## 2   London    22    16
## 3 New York    23    14
```

2.3. separate()함수

- 하나의 열을 특정 조건에 따라 여러개의 열로 나누어주는 함수 입니다.
- separate(data,col,into,sep,~) ** col:조건에 따른 분할을 진행할 열이름** into:분할된 결과가 저장될 각 열들의 이름** sep:분할 조건

```
storms2 <- separate(storms, date,c("year","month","day"),sep="-")
storms2
```

```
## # A tibble: 6 x 6
##   storm    wind pressure year  month day
```

```
##   <chr>   <int>    <int> <chr> <chr> <chr>
## 1 Alberto   110     1007 2000  08    03
## 2 Alex       45     1009 1998  07    27
## 3 Allison    65     1005 1995  06    03
## 4 Ana        40     1013 1997  06    30
## 5 Arlene     50     1010 1999  06    11
## 6 Arthur     45     1010 1996  06    17
```

2.4.unite() 함수

- 여러개로 나누어진 열을 특정 조건에 따라 결합해주는 함수입니다.
- unite(data,col,...,sep) ** col:조건에 따라 결합된 결과가 저장될 열이름 **...:합쳐질 열이름들** sep:결합시 구분자

```
unite(storms2,"date",year,month,day,sep="-")
```

```
## # A tibble: 6 x 4
##   storm    wind pressure date
##   <chr>   <int>    <int> <chr>
## 1 Alberto   110     1007 2000-08-03
## 2 Alex       45     1009 1998-07-27
## 3 Allison    65     1005 1995-06-03
## 4 Ana        40     1013 1997-06-30
## 5 Arlene     50     1010 1999-06-11
## 6 Arthur     45     1010 1996-06-17
```

3. dplyr

- dplyr은 Hadley Wickham이 만든 데이터 핸들링을 위한 패키지
- dplyr은 C++로 작성되어 기존 데이터핸들링 패키지보다 빠른조작이 가능
- 각종 데이터베이스 지원(MYSQL,Postgresql,SQLite,BigQeury)
- R의 기본문법과 프로그래밍능력만으로도 데이터의 조작이 가능하지만,dplyr 패키지를 활용하면 통일된 문법양식으로 데이터조작이 가능함
- 체인연산자를 지원함으로(%>%) 앞부분의 연산결과를 뒤에 오는 함수의 입력값으로 사용할 수 있음

dplyr의 주요함수

```
#filter() : 지정한 조건식에 맞는 데이터를 추출
#arrange() : 정렬
#select() : 열의 추출
#mutate() : 열추가
#summarise() ; 집계
```

dplyr 실습데이터:nycflights13

*미국 휴스턴에서 출발하는 모든 비행기의 이착륙

```
#install.packages("nycflights13) #해당패키지에 데이터가 있음
library(nycflights13)

## Warning: package 'nycflights13' was built under R version 3.6.3

library(dplyr)
head(flights)

## # A tibble: 6 x 19
##    year month   day dep_time sched_dep_time dep_delay arr_time
sched_arr_time
##   <int> <int> <int>    <int>          <int>     <dbl>    <int>
<int>
## 1  2013     1     1      517            515         2      830
819
## 2  2013     1     1      533            529         4      850
830
## 3  2013     1     1      542            540         2      923
850
## 4  2013     1     1      544            545        -1     1004
1022
## 5  2013     1     1      554            600        -6      812
837
## 6  2013     1     1      554            558        -4      740
728
## # ... with 11 more variables: arr_delay <dbl>, carrier <chr>, flight
<int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance
<dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

3.1 filter() 함수

- 데이터에서 원하는 조건에 따라 행을 추출하는 함수
- filter(데이터,조건1 | 조건2):조건1 또는 조건2 둘중 한가지를 충족하는 데이터를 추출*조건을 작성할때는 쉼표,'는AND,'|'는OR와 같음

```
filter(flights,month ==1 | day ==1)#37198row

## # A tibble: 37,198 x 19
##    year month   day dep_time sched_dep_time dep_delay arr_time
sched_arr_time
##   <int> <int> <int>    <int>          <int>     <dbl>    <int>
<int>
```

```
##  1  2013     1     1      517            515         2      830
819
##  2  2013     1     1      533            529         4      850
830
##  3  2013     1     1      542            540         2      923
850
##  4  2013     1     1      544            545        -1     1004
1022
##  5  2013     1     1      554            600        -6      812
837
##  6  2013     1     1      554            558        -4      740
728
##  7  2013     1     1      555            600        -5      913
854
##  8  2013     1     1      557            600        -3      709
723
##  9  2013     1     1      557            600        -3      838
846
## 10  2013     1     1      558            600        -2      753
745
## # ... with 37,188 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour
<dttm>

filter(flights,month==1|day==1) #842row

## # A tibble: 37,198 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time
sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>
<int>
##  1  2013     1     1      517            515         2      830
819
##  2  2013     1     1      533            529         4      850
830
##  3  2013     1     1      542            540         2      923
850
##  4  2013     1     1      544            545        -1     1004
1022
##  5  2013     1     1      554            600        -6      812
837
##  6  2013     1     1      554            558        -4      740
728
##  7  2013     1     1      555            600        -5      913
854
##  8  2013     1     1      557            600        -3      709
723
##  9  2013     1     1      557            600        -3      838
846
```

```
## 10  2013     1     1      558            600        -2      753
745
## # ... with 37,188 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour
<dttm>
```

```
filter(flights,month==1,day==1,year==2013)#832row
```

```
## # A tibble: 842 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time
sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>
<int>
##  1  2013     1     1      517            515         2      830
819
##  2  2013     1     1      533            529         4      850
830
##  3  2013     1     1      542            540         2      923
850
##  4  2013     1     1      544            545        -1     1004
1022
##  5  2013     1     1      554            600        -6      812
837
##  6  2013     1     1      554            558        -4      740
728
##  7  2013     1     1      555            600        -5      913
854
##  8  2013     1     1      557            600        -3      709
723
##  9  2013     1     1      557            600        -3      838
846
## 10  2013     1     1      558            600        -2      753
745
## # ... with 832 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour
<dttm>
```

3.2 arrange() 함수

- 데이터를 원한느 조건에 따라 정렬해주는 함수
- arrange(데이터,정렬기준컬럼1,정렬기준컬럼2,정렬기준컬럼3)
- 내림차순으로 정렬시 desc 함수 사용: arrange(데이터,desc(정렬기준컬럼1))

```
arrange(flights,year,month,day)# ArrDelay, Month,Year 순으로 정렬
```

```
## # A tibble: 336,776 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time
```

```
sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>
<int>
##  1  2013     1     1      517            515         2      830
819
##  2  2013     1     1      533            529         4      850
830
##  3  2013     1     1      542            540         2      923
850
##  4  2013     1     1      544            545        -1     1004
1022
##  5  2013     1     1      554            600        -6      812
837
##  6  2013     1     1      554            558        -4      740
728
##  7  2013     1     1      555            600        -5      913
854
##  8  2013     1     1      557            600        -3      709
723
##  9  2013     1     1      557            600        -3      838
846
## 10  2013     1     1      558            600        -2      753
745
## # ... with 336,766 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour
<dttm>

arrange(flights,desc(month)) #Month 컬럼기준으로 내림차순으로 정렬

## # A tibble: 336,776 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time
sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>
<int>
##  1  2013    12     1       13           2359        14      446
445
##  2  2013    12     1       17           2359        18      443
437
##  3  2013    12     1      453            500        -7      636
651
##  4  2013    12     1      520            515         5      749
808
##  5  2013    12     1      536            540        -4      845
850
##  6  2013    12     1      540            550       -10     1005
1027
##  7  2013    12     1      541            545        -4      734
755
##  8  2013    12     1      546            545         1      826
```

```
835
##  9  2013    12     1      549            600       -11      648
659
## 10  2013    12     1      550            600       -10      825
854
## # ... with 336,766 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour
<dttm>
```

3.3. select() 함수

- select함수는 원하는 열(column)을 추출
- select(데이터,컬럼1,컬럼2,컬럼3)
- select(데이터,컬럼1:컬럼3)
- 컬럼명을 변경할수 있음

```
select(flights,year,month,day)
```

```
## # A tibble: 336,776 x 3
##     year month   day
##    <int> <int> <int>
##  1  2013     1     1
##  2  2013     1     1
##  3  2013     1     1
##  4  2013     1     1
##  5  2013     1     1
##  6  2013     1     1
##  7  2013     1     1
##  8  2013     1     1
##  9  2013     1     1
## 10  2013     1     1
## # ... with 336,766 more rows
```

```
select(flights,year:day)
```

```
## # A tibble: 336,776 x 3
##     year month   day
##    <int> <int> <int>
##  1  2013     1     1
##  2  2013     1     1
##  3  2013     1     1
##  4  2013     1     1
##  5  2013     1     1
##  6  2013     1     1
##  7  2013     1     1
##  8  2013     1     1
##  9  2013     1     1
```

```
## 10  2013     1     1
## # ... with 336,766 more rows

select(flights,-(year:day))

## # A tibble: 336,776 x 16
##    dep_time sched_dep_time dep_delay arr_time sched_arr_time arr_delay
carrier
##       <int>          <int>     <dbl>    <int>          <int>     <dbl>
<chr>
##  1      517            515         2      830            819        11 UA
##  2      533            529         4      850            830        20 UA
##  3      542            540         2      923            850        33 AA
##  4      544            545        -1     1004           1022       -18 B6
##  5      554            600        -6      812            837       -25 DL
##  6      554            558        -4      740            728        12 UA
##  7      555            600        -5      913            854        19 B6
##  8      557            600        -3      709            723       -14 EV
##  9      557            600        -3      838            846        -8 B6
## 10      558            600        -2      753            745         8 AA
## # ... with 336,766 more rows, and 9 more variables: flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance
<dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

3.4 distinct() 함수

- 중복항목을 제외한 데이터를 확인 할 수 있음(unique 함수와 동일)
- distinct(데이터, 컬럼명)

```
distinct(select(flights,tailnum))

## # A tibble: 4,044 x 1
##    tailnum
##    <chr>
##  1 N14228
##  2 N24211
##  3 N619AA
##  4 N804JB
##  5 N668DN
##  6 N39463
##  7 N516JB
##  8 N829AS
##  9 N593JB
## 10 N3ALAA
## # ... with 4,034 more rows

distinct(select(flights,origin,dest))
```

```
## # A tibble: 224 x 2
##    origin dest
##    <chr>  <chr>
##  1 EWR    IAH
##  2 LGA    IAH
##  3 JFK    MIA
##  4 JFK    BQN
##  5 LGA    ATL
##  6 EWR    ORD
##  7 EWR    FLL
##  8 LGA    IAD
##  9 JFK    MCO
## 10 LGA    ORD
## # ... with 214 more rows
```

3.5. mutate() 함수

- 기존 데이터 프레임에 새로운 열을 추가해줌
- 데이터프레임 내의 변수들을 활용해 새로운 변수를 만들때 효과적임
- 새로 생성한 변수를 해당 함수 내에서 바로 활용이 가능

```
#arr_delay - dep_delay 값으로 gain 컬럼 추가
mutate(flights,gain=arr_delay - dep_delay)
```

```
## # A tibble: 336,776 x 20
##     year month   day dep_time sched_dep_time dep_delay arr_time
sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>
<int>
##  1  2013     1     1      517            515         2      830
819
##  2  2013     1     1      533            529         4      850
830
##  3  2013     1     1      542            540         2      923
850
##  4  2013     1     1      544            545        -1     1004
1022
##  5  2013     1     1      554            600        -6      812
837
##  6  2013     1     1      554            558        -4      740
728
##  7  2013     1     1      555            600        -5      913
854
##  8  2013     1     1      557            600        -3      709
723
##  9  2013     1     1      557            600        -3      838
846
## 10  2013     1     1      558            600        -2      753
```

```
745
## # ... with 336,766 more rows, and 12 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour
<dttm>,
## #   gain <dbl>
```

```
#gain 컬럼을 만드는 동시에 gain 컬럼을 이용해 다수의 다른 변수를 생성가능
mutate(flights,
       gain = arr_delay - dep_delay,
       gain_per_hour = gain/(air_time/60))
```

```
## # A tibble: 336,776 x 21
##     year month   day dep_time sched_dep_time dep_delay arr_time
sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>
<int>
##  1  2013     1     1      517            515         2      830
819
##  2  2013     1     1      533            529         4      850
830
##  3  2013     1     1      542            540         2      923
850
##  4  2013     1     1      544            545        -1     1004
1022
##  5  2013     1     1      554            600        -6      812
837
##  6  2013     1     1      554            558        -4      740
728
##  7  2013     1     1      555            600        -5      913
854
##  8  2013     1     1      557            600        -3      709
723
##  9  2013     1     1      557            600        -3      838
846
## 10  2013     1     1      558            600        -2      753
745
## # ... with 336,766 more rows, and 13 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour
<dttm>,
## #   gain <dbl>, gain_per_hour <dbl>
```

3.6 summarise() 함수

- mean(),sd(),var(), median() 함수를 활용해 기술통계량을 확인
- 결과를 데이터프레임으로 반환함

```
summarise(flights, delay= mean(dep_delay,na.rm=TRUE))
```

```
## # A tibble: 1 x 1
##   delay
##   <dbl>
## 1  12.6
```

3.7 group_by() 함수

- 변수의 레벨에 따라 자료를 그룹화해줌
- 그룹에 따른 수치자료를 산출하고 싶을때 편리함
- summarize 함수와 함께 사용시 aggregate 함수와 같은기능
- ex) 직급에 따른 평균 연봉과 사용가능한 연차일수(휴가)를 구하고 싶을때

```
#비행기별로 그룹만들기
by_tailnum <- group_by(flights, tailnum) #비행기별로 그룹만들기

#비행기별 비행회수, 비행거리평균, 연착시간평균 산출
delay <- summarise(by_tailnum,count=n(),dist=mean(distance,na.rm=TRUE),
                   delay = mean(arr_delay,na.rm=TRUE))

#회수가 20회 이상 거리가 2000 이하인 비행기만 추출
delay <-filter(delay,count>20,dist<2000)
```

*위에서 만든 delay 데이터로 시각화

```
library(ggplot2)
ggplot(delay, aes(dist,delay)) +
  geom_point(aes(size = count), alpha = 1/2) +
  geom_smooth() +
  scale_size_area()

## `geom_smooth()` using method = 'gam' and formula 'y ~ s(x, bs = "cs")'

## Warning: Removed 1 rows containing non-finite values (stat_smooth).

## Warning: Removed 1 rows containing missing values (geom_point).
```

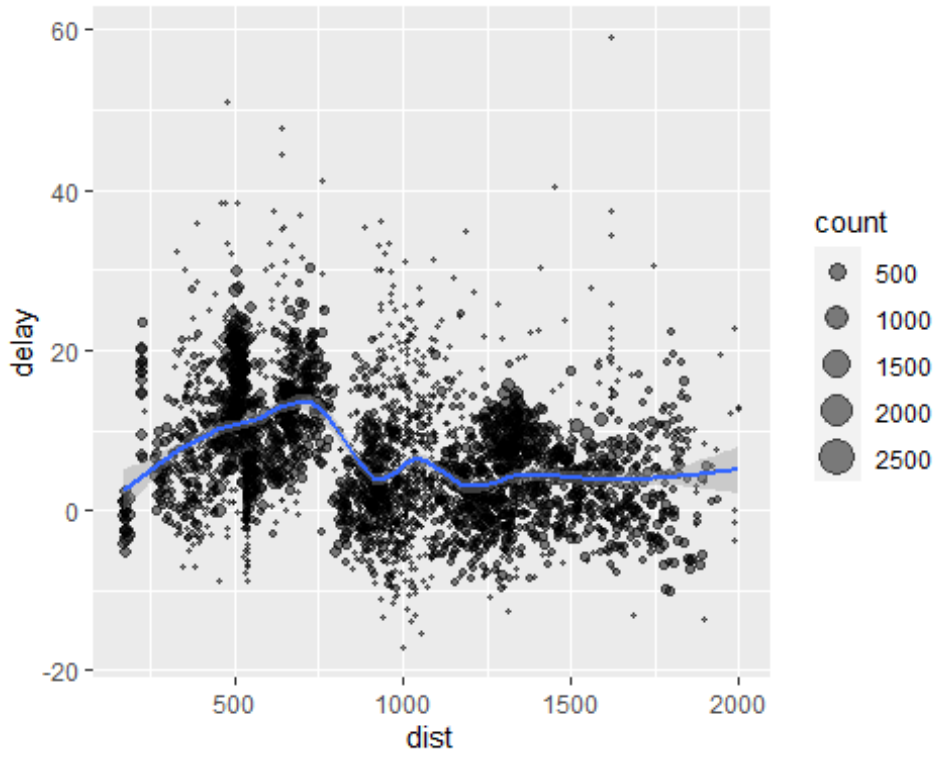

3.8. join()함수

- join(x,y)또는join(x,y,by="기준열")형태
- 조인의기준이되는단일컬럼이존재하는경우별도by인수를지정하지않아도됨
- 조인의기준이되는컬럼이여러개이거나, 여러가지컬럼을동시에활용해야하는경우by인수를사용

```
#join 실습 데이터 생성

superheroes <- "
name, alignment,gender, publisher
Magneto, bad, male, Marvel
Storm, good, female, Marvel
Mystique, bad ,female ,Marvel
Batman, good , male ,DC
Joker , bad, male, DC
Catwomer, bad ,female, DC
Hellboy, good male, Dark Horese Comics
"

publishers <- "
publisher, yr_founded
DC, 1934
Marvel, 1939
Image, 1992
```

```
"

superheroes <- read_csv(superheroes,trim_ws = TRUE, skip = 1)

## Warning: 1 parsing failure.
## row col  expected    actual         file
##   7  -- 4 columns 3 columns literal data

publishers <-read_csv(publishers,trim_ws= TRUE,skip=1)
```

- inner_join, left_join,anti_join,semi_join 각각의 출력값 확인하기

```
inner_join(superheroes,publishers) #X,Y의 교집합

## Joining, by = "publisher"

## # A tibble: 6 x 5
##   name     alignment gender publisher yr_founded
##   <chr>    <chr>     <chr>  <chr>          <dbl>
## 1 Magneto  bad       male   Marvel          1939
## 2 Storm    good      female Marvel          1939
## 3 Mystique bad       female Marvel          1939
## 4 Batman   good      male   DC              1934
## 5 Joker    bad       male   DC              1934
## 6 Catwomer bad       female DC              1934

left_join(superheroes,publishers) #X기준(왼쪽)으로 머징

## Joining, by = "publisher"

## # A tibble: 7 x 5
##   name     alignment gender             publisher yr_founded
##   <chr>    <chr>     <chr>              <chr>          <dbl>
## 1 Magneto  bad       male               Marvel          1939
## 2 Storm    good      female             Marvel          1939
## 3 Mystique bad       female             Marvel          1939
## 4 Batman   good      male               DC              1934
## 5 Joker    bad       male               DC              1934
## 6 Catwomer bad       female             DC              1934
## 7 Hellboy  good male Dark Horese Comics <NA>             NA

full_join(superheroes,publishers)# X,Y의 합집합

## Joining, by = "publisher"

## # A tibble: 8 x 5
##   name     alignment gender             publisher yr_founded
##   <chr>    <chr>     <chr>              <chr>          <dbl>
## 1 Magneto  bad       male               Marvel          1939
## 2 Storm    good      female             Marvel          1939
## 3 Mystique bad       female             Marvel          1939
```

```
## 4 Batman   good      male               DC              1934
## 5 Joker    bad       male               DC              1934
## 6 Catwomer bad       female             DC              1934
## 7 Hellboy  good male Dark Horese Comics <NA>              NA
## 8 <NA>     <NA>      <NA>               Image           1992

anti_join(superheroes,publishers) #X의 컬럼만 유지하여 머징

## Joining, by = "publisher"

## # A tibble: 1 x 4
##   name    alignment gender             publisher
##   <chr>   <chr>     <chr>              <chr>
## 1 Hellboy good male Dark Horese Comics <NA>

semi_join(superheroes,publishers) #Y의 여집합

## Joining, by = "publisher"

## # A tibble: 6 x 4
##   name     alignment gender publisher
##   <chr>    <chr>     <chr>  <chr>
## 1 Magneto  bad       male   Marvel
## 2 Storm    good      female Marvel
## 3 Mystique bad       female Marvel
## 4 Batman   good      male   DC
## 5 Joker    bad       male   DC
## 6 Catwomer bad       female DC
```

4.margrittr

- magrittr 패키지는 연산자(operator)들의 집합들을 제공합니다.
- 데이터 연산을 왼쪽에서 오른쪽 순서로 구조화;
- nested 함수 호출을 피함;
- 지역 변수 및 함수의 정의의 필요성을 최소화;
- 연산 순서 내에서 어디서나 추가 step을 만들 수 있음
- f(x)를 x%>%f()로 대체할 수 있음
- 이 연산자가 main operator(chaining) 인데 해당 기능이 의미없어 보이겠지만 여러가지 기능을 결합하여 사용할때 이점이 명확하다*dplyr을 불러오면 자동으로 불러와지게 된다

4.1 main operator (Chaining; %>%)

- 여러단계의 함수나 연산을 연결하여 한번에 수행할 때 사용

- 앞의 함수의 결과는 바로 뒤에오는 함수의 입력값이 됨
- 데이터를 여러객체에 할당하지 않아도 되기 때문에 메모리 관리에 유리함

체인연산 사용하지 않을때

```
a1 <- dplyr::group_by(flights, year,month,day)
a2 <- select(a1,year:day,arr_delay)
a3 <- summarise(a2,arr= mean(arr_delay,na.rm=TRUE))
a4 <- filter(a3,arr>30)
a4
```

```
## # A tibble: 42 x 4
## # Groups:   year, month [11]
##     year month   day   arr
##    <int> <int> <int> <dbl>
##  1  2013     1    16  34.2
##  2  2013     1    31  32.6
##  3  2013     2    11  36.3
##  4  2013     2    27  31.3
##  5  2013     3     8  85.9
##  6  2013     3    18  41.3
##  7  2013     4    10  38.4
##  8  2013     4    12  36.0
##  9  2013     4    18  36.0
## 10  2013     4    19  47.9
## # ... with 32 more rows
```

체인연산 사용했을때

```
flights %>%
  group_by(year,month,day) %>%
  select(arr_delay) %>%
  summarise(
    arr = mean(arr_delay,na.rm=TRUE)
  ) %>%
  filter(arr>30)
```

```
## Adding missing grouping variables: `year`, `month`, `day`
```

```
## # A tibble: 42 x 4
## # Groups:   year, month [11]
##     year month   day   arr
##    <int> <int> <int> <dbl>
##  1  2013     1    16  34.2
##  2  2013     1    31  32.6
##  3  2013     2    11  36.3
##  4  2013     2    27  31.3
```

```
##  5  2013     3     8  85.9
##  6  2013     3    18  41.3
##  7  2013     4    10  38.4
##  8  2013     4    12  36.0
##  9  2013     4    18  36.0
## 10  2013     4    19  47.9
## # ... with 32 more rows
```

4.2. .의 역할

- “.”의 역할에 대해서 알아봅시다.
- 일반적으로 %>% 연산자만 사용하시게 되면 제일 첫 인수에 자동으로 배정이 됩니다.

```
head(iris,3)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
```

```
iris %>% head(3) # = head(.,3)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
```

데이터를 넘겨줘야 할 인수의 위치가 첫번째가 아닐 경우 다음과 같은 에러를 확인할 수 있음 gsub()는 찾아 바꾸는 함수로써, 사용방법은gusb(찾을 문자나 숫자,바꿀 문자나 숫자,데이터)

```
a<-c("bannananana","an apple")
gsub("n","l",a)
```

```
## [1] "ballalalala" "al apple"
```

```
a %>% gsub("n","l")
```

```
## Warning in gsub(., "n", "l"): 인자 'pattern'는 반드시 길이가 1 보다 커야 하고,
## 오로지 첫번째 요소만이 사용될 것입니다
```

```
## [1] "l"
```

```
a %>% gsub("n","l")
```

```
## Warning in gsub(., "n", "l"): 인자 'pattern'는 반드시 길이가 1 보다 커야 하고,
## 오로지 첫번째 요소만이 사용될 것입니다
```

```
## [1] "l"
```

```r
gsub("n","l",a)
```

```
## [1] "ballalalala" "al apple"
```

```r
a %>% gsub("n","l",.)
```

```
## [1] "ballalalala" "al apple"
```

4.3 Chaining 예제

4.3.1 matcars aggregate

```r
library(magrittr)
```

```
## Warning: package 'magrittr' was built under R version 3.6.3
```

```
##
## Attaching package: 'magrittr'
```

```
## The following object is masked from 'package:purrr':
##
##     set_names
```

```
## The following object is masked from 'package:tidyr':
##
##     extract
```

```r
car_data <-
  mtcars %>%                  #1
  subset(hp>100) %>%          #2
  aggregate(.~cyl, data=., FUN= . %>% mean %>% round(2)) %>% #3
  transform(kpl = mpg %>% multiply_by(0.4251)) %>% #4
  print #5
```

```
##   cyl   mpg   disp     hp drat   wt  qsec   vs   am gear carb       kpl
## 1   4 25.90 108.05 111.00 3.94 2.15 17.75 1.00 1.00 4.50 2.00 11.010090
## 2   6 19.74 183.31 122.29 3.59 3.12 17.98 0.57 0.43 3.86 3.43  8.391474
## 3   8 15.10 353.10 209.21 3.23 4.00 16.77 0.00 0.14 3.29 3.50  6.419010
```

```r
car_data <-
  transform(aggregate(.~cyl,
                      data=subset(mtcars,hp>100),
                      FUN =function(x) round(mean(x),2)),
            kpl = mpg*0.4251)
car_data
```

```
##   cyl   mpg   disp     hp drat   wt  qsec   vs   am gear carb       kpl
## 1   4 25.90 108.05 111.00 3.94 2.15 17.75 1.00 1.00 4.50 2.00 11.010090
## 2   6 19.74 183.31 122.29 3.59 3.12 17.98 0.57 0.43 3.86 3.43  8.391474
## 3   8 15.10 353.10 209.21 3.23 4.00 16.77 0.00 0.14 3.29 3.50  6.419010
```

4.3.2. 예제 변환

- 2.1. 예제 tidyr의 함수들도 chaining 연산과 함께 사용하면 직관적으로 사용할 수 있습니다.

```
cases %>% gather(Year, n, 2:4)
```

```
##   country Year     n
## 1      FR 2011  7000
## 2      DE 2011  5800
## 3      US 2011 15000
## 4      FR 2012  6900
## 5      DE 2012  6000
## 6      US 2012 14000
## 7      FR 2013  7000
## 8      DE 2013  6200
## 9      US 2013 13000
```

- 3.7. 예제 dplyr에서도 함께 쓰여 데이트럴 그룹화하고 수치를 요약하는 등의 작업에 특화되어있습니다.

```
# 비행기별 비행회수,  비행거리평균,  연착시간평균 산출
flights %>%
  group_by(tailnum) %>%
  summarise(
    count = n(),
    dist = mean(distance,na.rm = TRUE),
    delay = mean(arr_delay,na.rm = TRUE)
  )
```

```
## # A tibble: 4,044 x 4
##    tailnum count  dist  delay
##    <chr>   <int> <dbl>  <dbl>
##  1 D942DN      4  854. 31.5
##  2 N0EGMQ    371  676.  9.98
##  3 N10156    153  758. 12.7
##  4 N102UW     48  536.  2.94
##  5 N103US     46  535. -6.93
##  6 N104UW     47  535.  1.80
##  7 N10575    289  520. 20.7
##  8 N105UW     45  525. -0.267
##  9 N107US     41  529. -5.73
## 10 N108UW     60  534. -1.25
## # ... with 4,034 more rows
```

5. tibble

- tibble은 tidyverse 생태계에서 데이터프레임을 대신하여 편리한 기능들 및 동작을 포함한 자료형입니다.
- factor 자동 변환
- 일부값만 출력

- 출력시 자료형 명시
- 데이터 프레임과 비교

```
#생성 : data.frame()
#강제변환(Coercion) : as.data.frame()
#데이터 불러오기 : read.*()
```

5.1. tibble 생성

tibble()

```
tibble(
  x =1:5,
  y =1,
  z = x^2+y
)
```

```
## # A tibble: 5 x 3
##       x     y     z
##   <int> <dbl> <dbl>
## 1     1     1     2
## 2     2     1     5
## 3     3     1    10
## 4     4     1    17
## 5     5     1    26
```

tribble() * 코드 단계에서 데이터를 입력받도록 하기 위해 존재하는 함수입니다.

```
tribble(
  ~x,~y,~z,
  #---/--/----
  "a",2,3.6,
  "b",1,8.5
)
```

```
## # A tibble: 2 x 3
##   x         y     z
##   <chr> <dbl> <dbl>
## 1 a         2   3.6
## 2 b         1   8.5
```

as_tibble() * 기존의 데이터 프레임을 tibble 형으로 전환합니다.

```
iris_tibble<- as_tibble(iris) #기존의 데이터프레임을 tibble로

print(class(iris)) #기존의 데이터 프레임 클래스
```

```
## [1] "data.frame"
```

```
print(class(iris_tibble)) #새롭게 정의된 tibble 클래스 ( 데이터 프레임도)
```

```
## [1] "tbl_df"     "tbl"        "data.frame"
```

```
head(iris_tibble)
```

```
## # A tibble: 6 x 5
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
##          <dbl>       <dbl>        <dbl>       <dbl> <fct>
## 1          5.1         3.5          1.4         0.2 setosa
## 2          4.9         3            1.4         0.2 setosa
## 3          4.7         3.2          1.3         0.2 setosa
## 4          4.6         3.1          1.5         0.2 setosa
## 5          5           3.6          1.4         0.2 setosa
## 6          5.4         3.9          1.7         0.4 setosa
```

5.2. 데이터 불러오기

- 데이터를 읽어올 때, dataframe이 아닌tibble로 읽어오기 위해서,동일한tidyverse 생태계에 속한 readr 패키지의 함수들을 필요로합니다. 이미tidyverse를library하였으므로 바로 이용 가능합니다.

read_csv(file)

*기존의 데이터 불러오기와 동일하게 파일명을 지정하여 해당 파일을tibble로 읽어올 수 있습니다.

```
read_csv("traffic.csv")
```

```
## Warning: Missing column names filled in: 'X1' [1]
```

```
## Parsed with column specification:
## cols(
##   X1 = col_double(),
##   rpt.id = col_character(),
##   rpt.contents = col_character(),
##   info.tp = col_character(),
##   info.tit = col_character(),
##   occ.dtime = col_date(format = ""),
##   reg.dtime = col_time(format = ""),
##   end.dtime = col_date(format = ""),
##   start.pos.x = col_double(),
##   start.pos.y = col_double(),
##   end.pos.x = col_double(),
##   end.pos.y = col_double()
## )
```

```
## # A tibble: 500 x 12
##       X1 rpt.id rpt.contents info.tp info.tit occ.dtime  reg.dtime
```

```
end.dtime
##    <dbl> <chr>  <chr>          <chr>   <chr>    <date>     <time>    <date>
##  1     1 01149~ 서부간선도로 안양방면~ A4       단순정보 2014-06-15 17:17     2014-
06-15
##  2     2 01149~ 동부간선도로 성수대교~ A4       단순정보 2014-06-15 17:16     2014-
06-15
##  3     3 01149~ 북부간선도로 종암분가~ A4       단순정보 2014-06-15 17:16     2014-
06-15
##  4     4 01149~ 올림픽대로 공항방면 ~ A4       단순정보 2014-06-15 17:15     2014-
06-15
##  5     5 01149~ 강변북로 (일산 → ~ A1        단순사고 2014-06-15 17:15     2014-
06-15
##  6     6 01149~ 내부순환로 성수대교방~ A4       단순정보 2014-06-15 17:14     2014-
06-15
##  7     7 01149~ 평택-시흥간고속도로 ~ A4       단순정보 2014-06-15 17:14     2014-
06-15
##  8     8 01149~ 서울-춘천간고속도로 ~ A4       단순정보 2014-06-15 17:13     2014-
06-15
##  9     9 01149~ 천안-논산간고속도로 ~ A4       단순정보 2014-06-15 17:13     2014-
06-15
## 10    10 01149~ 영동고속도로 강릉방면~ A4       단순정보 2014-06-15 17:12     2014-
06-15
## # ... with 490 more rows, and 4 more variables: start.pos.x <dbl>,
## #   start.pos.y <dbl>, end.pos.x <dbl>, end.pos.y <dbl>
```

read_csv(csv_url)

- 외부에서 공개된 csv 파일도 바로 읽어올 수 있습니다. ** github,gist,google drive

```
file_url <-
"https://gist.githubusercontent.com/theoroe3/8bc989b644adc24117bc66f50c292fc8
/raw/f677a2ad811a9854c9d174178b0585a87569af60/tibbles_data.csv"
read_csv(file_url)
```

```
## Parsed with column specification:
## cols(
##   `<-` = col_double(),
##   `8` = col_double(),
##   `%` = col_double(),
##   name = col_character()
## )

## # A tibble: 4 x 4
##    `<-`    `8`    `%` name
##   <dbl> <dbl> <dbl> <chr>
## 1     1     2  0.25 t
```

```
## 2     2     4  0.25 h
## 3     3     6  0.25 e
## 4     4     8  0.25 o
```

locale 설정* 한글이 포함된 데이터를 읽어올 때, read.csv에서 fileEncoding으로 조정을 하였습니다. * read_csv 에서는 주로locale 인자를 설정해 주어야하는데, 통상적으로local('ko',encoding='euc-kr')와 같이 설정해줍니다. * 예제는 아래의 연습문제에서 데이터를 불러오는것으로 알아보겠습니다.

PR12 연습문제

문제1

- 다음은 광주광역시의 연도별 폐기물 발생현황입니다.

```
waste <-read_csv("광주광역시_연도별 폐기물
발생현황_20171231.csv",locale=locale('ko',encoding='euc-kr'))

## Parsed with column specification:
## cols(
##   대분류 = col_character(),
##   중분류 = col_character(),
##   소분류 = col_character(),
##   `2008년` = col_double(),
##   `2009년` = col_double(),
##   `2010년` = col_double(),
##   `2011년` = col_double(),
##   `2012년` = col_double(),
##   `2013년` = col_double(),
##   `2014년` = col_double(),
##   `2015년` = col_double(),
##   `2016년` = col_double(),
##   `2017년` = col_double()
## )

waste

## # A tibble: 22 x 13
##    대분류 중분류 소분류 `2008년` `2009년` `2010년` `2011년` `2012년` `2013년`
##    <chr>  <chr>  <chr>     <dbl>    <dbl>    <dbl>    <dbl>    <dbl>
```

```
<dbl>
##  1 생활폐기물~ 가정생활폐~ 매립      273.     255      235.     206.     209.
201.
##  2 생활폐기물~ 가정생활폐~ 소각      246.     247.     232.     203      234.
242.
##  3 생활폐기물~ 가정생활폐~ 재활용    805.     801.     771.     745.     726.
752
##  4 생활폐기물~ 사업장생활~ 매립       21.8     35       31.4     32.1     29.6
28.8
##  5 생활폐기물~ 사업장생활~ 소각       40.2     20.8     17.9     18.8     29.8
29
##  6 생활폐기물~ 사업장생활~ 재활용     95.3     71.2    109.     129.     100.
73.6
##  7 사업장배출~ 사업장배출~ 매립      163.     161.     230.     237.     213.
206.
##  8 사업장배출~ 사업장배출~ 소각       57.4     48.5     53.1     47.8     37.2
40.6
##  9 사업장배출~ 사업장배출~ 재활용    415.     370      422.     437.     490.
504.
## 10 사업장배출~ 사업장배출~ 해역배출~     10.1    107.      63.2     70.6      5.3
6
## # ... with 12 more rows, and 4 more variables: `2014년` <dbl>, `2015년`
<dbl>,
## #   `2016년` <dbl>, `2017년` <dbl>
```

- gather를 사용하여waste를 아래와 같은long 데이터 포맷으로 나타내보세요

```
gather(waste,Year,n,4:13)
```

```
## # A tibble: 220 x 5
##    대분류                  중분류                  소분류   Year       n
##    <chr>                   <chr>                   <chr>    <chr>  <dbl>
##  1 생활폐기물              가정생활폐기물          매립     2008년 273.
##  2 생활폐기물              가정생활폐기물          소각     2008년 246.
##  3 생활폐기물              가정생활폐기물          재활용   2008년 805.
##  4 생활폐기물              사업장생활계폐기물      매립     2008년  21.8
##  5 생활폐기물              사업장생활계폐기물      소각     2008년  40.2
##  6 생활폐기물              사업장생활계폐기물      재활용   2008년  95.3
##  7 사업장배출시설계폐기물 사업장배출시설계폐기물  매립     2008년 163.
##  8 사업장배출시설계폐기물 사업장배출시설계폐기물  소각     2008년  57.4
```

```
##  9 사업장배출시설계폐기물 사업장배출시설계폐기물 재활용    2008년 415.
## 10 사업장배출시설계폐기물 사업장배출시설계폐기물 해역배출 2008년  10.1
## # ... with 210 more rows
```

문제2

*다음은 서울시 공공자전거 따릉이의 2019년 5월 대여에 관한 정보입니다.

```
bike_tibble <- read_csv("bike_sample.csv")
```

```
## Parsed with column specification:
## cols(
##   대여일자 = col_date(format = ""),
##   대여시간 = col_double(),
##   대여소번호 = col_double(),
##   대여소명 = col_character(),
##   대여구분코드 = col_character(),
##   성별 = col_character(),
##   연령대코드 = col_character(),
##   이용건수 = col_double(),
##   운동량 = col_character(),
##   탄소량 = col_character(),
##   이동거리 = col_double(),
##   이동시간 = col_double()
## )
```

- 해당 데이터에서 다음과 같이 연령대별 정보를 요약해보세요.

```
by_age <- bike_tibble %>%
  group_by(연령대코드) %>%
  summarize(count=n(),rentalmean=mean(이용건수))

print(by_age)
```

```
## # A tibble: 7 x 3
##   연령대코드 count rentalmean
##   <chr>      <int>      <dbl>
## 1 ~10대         24       1.25
## 2 20대         209       1.48
## 3 30대         143       1.24
```

```
## 4 40대          74       1.12
## 5 50대          36       1.08
## 6 60대          11       1
## 7 70대~          3       1
```

문제3

- raw.csv는 국회의원 별 의원비 지출내역이고, join.csv는 국회의원 명단입니다.

```
raw_data <- read_csv("raw.csv", locale=locale('ko',encoding='euc-kr'))
```

```
## Warning: Missing column names filled in: 'X1' [1]
```

```
## Parsed with column specification:
## cols(
##   X1 = col_double(),
##   total_num = col_double(),
##   cong_num = col_double(),
##   name = col_character(),
##   party = col_character(),
##   region = col_character(),
##   date = col_date(format = ""),
##   item = col_character(),
##   expense = col_double(),
##   store = col_character(),
##   category = col_character(),
##   region2 = col_character(),
##   date2 = col_date(format = ""),
##   date_month = col_character()
## )
```

```
join_data <-read_csv("join.csv",locale=locale("ko",encoding='euc-kr'))
```

```
## Warning: Missing column names filled in: 'X1' [1], 'X16' [16], 'X17' [17],
## 'X18' [18], 'X19' [19]
```

```
## Warning: Duplicated column names deduplicated: 'achievement' =>
## 'achievement_1' [15]
```

```
## Parsed with column specification:
## cols(
##   X1 = col_double(),
##   region = col_character(),
##   district = col_character(),
##   party = col_character(),
##   name = col_character(),
##   gender = col_character(),
##   birth = col_date(format = ""),
##   job = col_character(),
```

```
##   achievement = col_character(),
##   career = col_character(),
##   vote_rate = col_number(),
##   age = col_double(),
##   regeion = col_character(),
##   job2 = col_character(),
##   achievement_1 = col_character(),
##   X16 = col_character(),
##   X17 = col_character(),
##   X18 = col_character(),
##   X19 = col_double()
## )

raw_data ; names(raw_data)

## # A tibble: 146,224 x 14
##       X1 total_num cong_num name  party region date       item  expense
store
##    <dbl>     <dbl>    <dbl> <chr> <chr> <chr>  <date>     <chr>   <dbl>
<chr>
##  1     1    217616      309 현영희~ 무소속~ 비례   2014-01-03 항공료~   68600
대한항공~
##  2     2    217617      309 현영희~ 무소속~ 비례   2014-01-03 전문가 ~   78000
카페모차~
##  3     3    217618      309 현영희~ 무소속~ 비례   2014-01-03 항공료~   97100
대한항공~
##  4     4    217619      309 현영희~ 무소속~ 비례   2014-01-03 유류비~  138000
예스제아~
##  5     5    217620      309 현영희~ 무소속~ 비례   2014-01-05 유류비~   60000
과정로셀~
##  6     6    221930        1 강기윤~ 새누리당~ 경남 창원~ 2014-01-02 우편발송~
3070 창원우체~
##  7     7    221931        1 강기윤~ 새누리당~ 경남 창원~ 2014-01-03 식대   111000
초기집삭~
##  8     8    221932        1 강기윤~ 새누리당~ 경남 창원~ 2014-01-04 차량 L~
61254 광산개발~
##  9     9    221933        1 강기윤~ 새누리당~ 경남 창원~ 2014-01-06 커피 구~
30000 GS25~
## 10    10    221934        1 강기윤~ 새누리당~ 경남 창원~ 2014-01-06 식대    88000
일호추어~
```

```
## # ... with 146,214 more rows, and 4 more variables: category <chr>,
## #   region2 <chr>, date2 <date>, date_month <chr>

##  [1] "X1"         "total_num"  "cong_num"   "name"       "party"
##  [6] "region"     "date"       "item"       "expense"    "store"
## [11] "category"   "region2"    "date2"      "date_month"

join_data ; names(join_data)

## # A tibble: 300 x 19
##       X1 region district party name  gender birth      job   achievement
career
##    <dbl> <chr>  <chr>    <chr> <chr> <chr>  <date>     <chr> <chr>
<chr>
##  1    94 비례   비례대표 새누리당~ 민현주~ 여     1969-07-23 경기대학~ Cornell 대학~
(현) 경가~
##  2   135 비례   비례대표 새누리당~ 신경림~ 여     1954-03-22 이화여자~ Teachers C~
(현) 한국~
##  3   235 경기   하남시   새누리당~ 이현재~ 남     1949-04-25 정당인~ 건국대학교 대학원 ~
(전) 중소~
##  4   294 인천   남구갑   새누리당~ 홍일표~ 남     1956-02-11 국회의원~ 건국대학교 대학원 ~
(전) 인천~
##  5   185 충북   충주시   새누리당~ 윤진식~ 남     1946-03-04 국회의원~ 건국대학교
일반대학~ 전) 산업자~
##  6   131 비례   비례대표 새누리당~ 손인춘~ 여     1959-05-13 (주) 인~ 건국대학교 일반대학~
(현) (주~
##  7    69 서울   광진구갑 민주통합~ 김한길~ 남     1953-09-17 정당인~ 건국대학교 정치외교~
(전) 문화~
##  8   122 경기   광명시갑 민주통합~ 백재현~ 남     1951-07-04 국회의원~ 경기대학교 무역학과~
(현)  민~
##  9     4 전북   남원시순창군~ 통합진보~ 강동원~ 남     1953-01-20 정당인~ 경기대학교
정치전문~ (전) 농수~
## 10   192 서울   노원구갑 새누리당~ 이노근~ 남     1954-03-09 광운대학~ 경기대학교 정치전문~
(전) 노원~
## # ... with 290 more rows, and 9 more variables: vote_rate <dbl>, age
<dbl>,
## #   regeion <chr>, job2 <chr>, achievement_1 <chr>, X16 <chr>, X17 <chr>,
## #   X18 <chr>, X19 <dbl>

##  [1] "X1"           "region"       "district"     "party"
##  [5] "name"         "gender"       "birth"        "job"
```

```
##  [9] "achievement"   "career"        "vote_rate"     "age"
## [13] "regeion"       "job2"          "achievement_1" "X16"
## [17] "X17"           "X18"           "X19"
```

- 두 데이터를 조인하여 의원비 지출이 가장 많은 10 명의 직업과 학력을 확인하세요.
- HINT1 : 두 데이터를 조인하기 위해서는 raw.csv 의 데이터를 group_by(),summarise() 함수 또는 aggregate() 를 사용하여 요약해야함.
- HINT2 : 이름을 기준으로 join 할것

```
processed_data <- raw_data %>%
  group_by(name,party) %>%
  summarise(expense_sum=sum(expense)) %>%
  arrange(desc(expense_sum)) %>%
  head(10) %>%
  merge(join_data,by='name') %>%
  arrange(desc(expense_sum)) %>%
  head(10) %>%
  select(c(name,party.x,expense_sum,job,achievement)) %>%
  as_tibble() %>%
  mutate(job = as.character(job)) %>%
  mutate(achievement = as.character(achievement)) %>%
  mutate(party.x = as.character(party.x)) %>%
  mutate(name = as.character(name))


colnames(processed_data) <-
c('name','party','expense_sum','job','achievement')

print(processed_data)
```

```
## # A tibble: 10 x 5
##    name   party   expense_sum job              achievement
##    <chr>  <chr>         <dbl> <chr>            <chr>
##  1 이명수 새누리당~    446913569 국회의원          성균관대 대학원 졸업(행정학과 행정학
박사)~
##  2 김상민 새누리당~    402282444 대학생자원봉사단 V원정대 대표~ 아주대학교 사학과졸업
##  3 조원진 새누리당~    392767643 국회의원          영남대학교 행정대학원 정책분석학과
졸업(행정학 석사)~
##  4 서상기 새누리당~    351375323 국회의원          美 드렉셀대학교
공학박사(1972.09~1976.06)~
##  5 이상규 통합진보~    346551904 정당인            서울대학교 법과대학 공법학과 졸업~
##  6 심상정 진보정의~    336436592 정당인            서울대학교 사회교육과 졸업
##  7 박지원 새정치      331136715 국회의원          단국대 상학과 졸업
```

```
##  8 정병국 새누리당~     330634706 국회의원                 성균관 대학교 대학원 졸업(정치학박사)~
##  9 유성엽 새정치       330615390 국회의원                 서울대학교 사회과학대학 외교학과 졸업~
## 10 이종걸 새정치       323533338 변호사                   서울대학교 법과대학 공법학과 졸업~
```